

Úloha s lineárním neuronem

Uvažujme vstupní signál jako funkci času $u(t)$ a odezvu systému (reakci na tento signál) $y(t)$. Vstupní i výstupní signál máme v podobě vektoru \mathbf{u} a vektoru \mathbf{y} , kde jednotlivé prvky odpovídají jednotlivým hodnotám změřeným s konstatním vzorkováním, viz soubor *uy.txt*¹.

Cílem je predikovat chování systému (tedy nějakým způsobem predikovat hodnoty funkce v určitém čase $y(t)$), v závislosti na zadaném vstupu $u(t)$ a stavu systému v minulosti, tedy $y(t_i < t)$. Využijeme proto diskrétních dat a provedeme tzv. lineární interpolaci (resp. sestrojíme lineární neuron) v podobě

$$Y_{\text{pred}} = \mathbf{W} \cdot \mathbf{X}$$

kde Y_{pred} značí predikovanou hodnotu, \mathbf{W} vektor vah, které budeme chtít určit a \mathbf{X} vektor argumentů neuronu. Konstrukce lineárního neuronu spočívá právě ve vhodné volbě argument pro neuron \mathbf{X} .

V našem případě budeme volit

$$Y_{\text{pred}}(t_k) = \mathbf{W} \cdot \mathbf{X}(t_k, \mathbf{u}, \mathbf{y})$$

$$Y_{\text{pred}}(t_k) = \mathbf{W} \cdot \mathbf{X} = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \end{bmatrix} \cdot \begin{bmatrix} y(t_{k-1}) \\ y(t_{k-2}) \\ u(t_{k-1}) \\ u(t_{k-2}) \end{bmatrix} \quad (1)$$

neboli hodnota v časovém kroku t_k bude *předpovězena* na základě vstupního signálu u v předchozích dvou krocích (tj. $u(t_{k-1})$ a $u(t_{k-2})$) a skutečného stavu systému y v předchozích dvou krocích (tj. $y(t_{k-1})$ a $y(t_{k-2})$) a kombinaci váhových parametrů \mathbf{W} , které musíme určit.

Algoritmus programu

- K dispozici máme N časových kroků k , jednotlivé hodnoty vektorů \mathbf{u} a \mathbf{y} odpovídají jednotlivým časovým krokům
- V každém časovém kroku k vyčíslíme vektor $\mathbf{X}(t_k)$
- Provedeme predikci hodnot $Y_{\text{pred}}(t_k) = \mathbf{W} \cdot \mathbf{X}(t_k)$
- Určíme chybu mezi měřenými daty a vypočítanou (predikovanou) hodnotou $e(t_k) = y(t_k) - Y_{\text{pred}}(t_k)$
- Určíme, o kolik je potřeba změnit koeficienty \mathbf{W} tj. $\Delta \mathbf{W}(t_k) = \mu e(t_k) \mathbf{X}(t_k)$, přičemž $\mu = 0.1$ je tzv. *learning rate*
- Provedeme aktualizaci vah $\mathbf{W} = \mathbf{W} + \Delta \mathbf{W}(t_k)$

Celý proces opakujeme 10-krát, tj. provedeme 10 *epoch* trénování. Poté bychom měli mít již dostatečně dobře přizpůsobené váhy a dostatečně dobrou predikci hodnot $Y_{\text{pred}}(t_k)$, resp. vektoru \mathbf{Y}_{pred} .

pozn. Vektor \mathbf{W} inicializujte náhodnými čísly.

pozn. Jedná se o tzv. krokovou adaptaci, učení (přizpůsobování vah) se děje v každém časovém kroku.

¹Data a námět jsou s laskavým poděkováním převzata z ukázek Doc. Bukovského.

Zpracování výsledků

Výsledky zobrazte pomocí funkce *subplot* (*help subplot*) jako tři grafy pod sebou.

- V prvním grafu bude vynesena vstupní signál a měřená data
- V druhém grafu budou vynesena měřená a predikovaná data
- Ve třetím grafu bude vynesena chyba mezi predikovanými a měřenými daty

pozn. Kde se bere vztah pro aktualizaci vah?

Po provedení predikce pomocí neuronu určujeme rozdíl mezi predikovanými a měřenými (trénovacími daty) jako $e(t_k) = y(t_k) - Y_{\text{pred}}(t_k)$. Následně zavedeme tzv. *chybové kritérium* $Q(t_k)$, tedy nějakou funkci chyby v časovém kroku, například kvadrát chyby $Q(t_k) = e^2(t_k)$, který vystihuje *vzdálenost* mezi trénovacími daty a predikovanou hodnotou.

Protože k predikci jsme použili seznam vah \mathbf{W} a protože predikce nedává hodnotu, která by přesně odpovídala měřeným datům, je potřeba vhodným způsobem upravit koeficienty \mathbf{W} tak, abychom minimalizovali chybu e . Kde je minimalizace, tam je gradient. Zvolíme tedy změnu hodnot vah $\Delta\mathbf{W}$ tak, že půjde o nějaký přírůstek ve směru gradientu chyby e , neboli

$$\mathbf{W}(t_k) = \mathbf{W}(t_{k-1}) + \Delta\mathbf{W}(t_k); \quad \Delta\mathbf{W} = -\frac{\partial Q(t_k)}{\partial \mathbf{W}} \frac{\mu}{2}$$

kde μ je dodatečný, uměle vložený koeficient (tzv. *koeficient učení, learning rate*) přidáný za účelem stabilizace. Po troše počítání

$$\Delta\mathbf{W} = \frac{\partial Q(t_k)}{\partial \mathbf{W}} \frac{\mu}{2} = -\frac{\partial e^2(t_k)}{\partial \mathbf{W}} \frac{\mu}{2} = -\frac{\partial e(t_k)}{\partial \mathbf{W}} 2e(t_k) \frac{\mu}{2} = -\frac{\partial e(t_k)}{\partial \mathbf{W}} 2e(t_k) \frac{\mu}{2} = -\mu_n e(t_k) \frac{\partial (y(t_k) - Y_{\text{pred}}(t_k))}{\partial \mathbf{W}} = \dots$$

kde jsme všechny konstanty zabalili do koeficientu učení μ a protože měřená data $y(t_k)$ jsou konstantní

$$\dots = \mu_n e(t_k) \frac{\partial Y_{\text{pred}}(t_k)}{\partial \mathbf{W}}$$

odtud je již patrné, že

$$\Delta\mathbf{W}(t_k) = \mu_n e(t_k) \mathbf{X}(t_k)$$